

텍스트 기반 보이스피싱
탐지 시스템 개발 프로젝트
결과보고서

프로젝트명 : 텍스트 기반 보이스피싱 탐지 시스템 개발

팀 리더 : 김나현 / 인공지능응용학과 / 22102304

팀원 : 장수효 / 인공지능응용학과 / 21102384

팀원 : 정지훈 / 인공지능응용학과 / 21102389

1. 요약서

팀 번호	1	공개가능여부	가
프로젝트명	텍스트 기반 보이스피싱 탐지 시스템 개발		
팀 리더	성 명	김나현	팀명 AIShield

○ 문제 정의

기존의 보이스피싱 차단은 주로 전화번호 블랙리스트나 문자 내 악성 URL 포함 여부와 같은 단순 패턴 매칭 방식에 의존하고 있어, 정상 번호를 도용하거나 교묘한 대화 흐름을 통해 피해자의 심리를 압박하는 고도화된 수법을 탐지하는 데 있어 한계가 존재한다. 본 프로젝트에서는 Knowledge Distillation 기법을 활용한 경량화된 온디바이스(On-Device) AI 모델을 구축하여, 개인정보 유출 없이 통화 내용의 문맥을 실시간으로 파악하고 보이스피싱 위험 탐지 및 예방 조언을 제공하는 것을 핵심 과제로 삼는다.

○ 제안한 설계내용 요약

본 설계는 STT 기반 텍스트 데이터와 생성형 AI를 활용한 증강 기법으로 데이터 부족 문제를 해결하고, Knowledge Distillation를 통해 고성능 모델을 온디바이스 환경에 맞게 경량화하였다. 이를 통해 외부 서버 통신 없이 스마트폰 내부에서 실시간 스트림 분석을 수행하여 개인정보 유출을 방지하며, 통화 중 즉각적인 피싱 탐지 및 맞춤형 대응 가이드를 제공하는 것을 핵심으로 한다.

○ 설계 구현 시 예측 가능한 기대효과

보이스피싱과 같은 데이터 희소 도메인에서 생성형 AI 기반 증강 기법의 유효성을 검증하고, Knowledge Distillation를 통해 저사양 환경에서도 고성능을 발휘하는 경량화 모델을 확보한다는 점에서 기술적 의의가 크다. 특히 민감 데이터의 외부 전송을 원천 차단하는 온디바이스(On-Device) 다중 작업(MTL) 아키텍처를 구현함으로써 개인정보 보호를 최우선으로 하는 금융·통신권 연계형 솔루션의 기틀을 마련하며, 궁극적으로는 실시간 탐지를 통한 실질적인 범죄 예방 및 사회적 피해 감소에 기여할 것으로 기대된다.

○ 키워드

보이스 피싱 탐지	NLP	Knowledge Distillation	Multi-task Learning
-----------	-----	------------------------	---------------------

1. 문제정의

본 프로젝트는 통화 내용을 STT(Speech-to-Text)로 변환한 텍스트를 실시간으로 분석하여, 보이스피싱 여부와 위험도를 판별하고 사용자에게 즉각적인 경고와 조언을 제공하는 **텍스트 기반 보이스피싱 탐지 및 경고 시스템을 개발**하는 것이다.

기존의 보이스피싱 차단은 주로 전화번호 블랙리스트나 문자 내 악성 URL 포함 여부와 같은 단순 패턴 매칭 방식에 의존하고 있어, 정상 번호를 도용하거나 교묘한 대화 흐름을 통해 피해자의 심리를 압박하는 고도화된 수법을 탐지하는 데 있어 한계가 존재한다.

따라서 본 프로젝트에서는 Knowledge Distillation 기법을 활용한 경량화된 온디바이스(On-Device) AI 모델을 구축하여, 개인정보 유출 없이 통화 내용의 문맥을 실시간으로 파악하고 보이스피싱 위험 탐지 및 예방 조언을 제공하는 것을 핵심 과제로 삼는다.

2. 문제의 현황

보이스피싱 범죄의 가해자는 주로 조직화된 범죄 집단으로, 이들은 금융기관이나 수사기관 등을 사칭하는 정교한 시나리오를 활용해 대규모 피해를 유발하고 있다. 특히 기관 사칭형 보이스피싱이 전체의 절반 이상을 차지하는 것으로 알려져 있으며, 피해자는 IT 활용 능력이 상대적으로 취약한 50대 이상 장·노년층이 약 53%로 가장 큰 비중을 차지하고 있어 사회적 취약계층을 중심으로 피해가 집중되는 양상을 보인다.

2025년 경찰청 통계에 따르면, 2025년 1월부터 3월까지의 보이스피싱 발생 건수는 전년 동기 대비 약 17% 증가하였고, 같은 기간 피해액은 약 3,166억 원으로 120% 이상 폭증한 것으로 보고된다. 보이스피싱은 특정 시기나 시간대에 국한되지 않고 연중 상시 발생하며, 평일과 주말, 주간과 야간을 가리지 않고 지속적으로 발생하고 있다. 특

히 통화가 진행되는 도중, 피해자가 심리적으로 몰려 판단력이 흐려지는 시점에 송금이나 인증을 요구하는 경우가 많아, 실시간 탐지와 경고가 이루어지지 않으면 피해를 예방하기 어렵다는 특성이 존재한다. 보이스피싱이 주로 발생하는 곳은 음성통화이므로 물리적 위치는 가정, 직장, 이동 중 어디든 될 수 있으며, 결국 디지털 통신망이 연결된 모든 장소가 잠재적인 피해 공간이 된다. 또한 많은 범죄가 서버·콜센터, 해외 중계지 등을 활용해 이루어지기 때문에, 범죄 발생 이후의 추적과 단속만으로는 근본적인 대응에 한계가 있다.

기존 스팸 차단 시스템은 주로 전화번호 기반 블랙리스트나 악성 URL 포함 여부 등과 같이 사전에 정의된 고정 패턴에 의존하고 있다. 그러나 보이스피싱 조직은 발신 번호를 수시로 변경하거나 정상 번호를 도용하고, 대화 자체를 통해 신뢰를 쌓으며, 계좌 동결, 압수수색, 가족 사고 등의 위급 상황을 연출함으로써 피해자에게 강한 심리적 압박을 가한다. 이와 같은 방식은 통화 내용의 의미와 맥락을 해석하지 못하는 기존 시스템으로는 탐지가 매우 어렵기 때문에, 통화 음성을 STT로 변환한 텍스트를 기반으로 문맥을 분석하여 보이스피싱 여부와 위험도를 판단할 수 있는 AI 모델의 도입이 필수적인 상황이다.

3. 문제의 필요성과 중요성

보이스피싱 문제는 단순한 개별 범죄를 넘어, 국가 경제와 사회 전반에 심각한 영향을 미치는 구조적인 문제이다. 최근 몇 년 사이 보이스피싱 피해 건수와 피해액은 지속적으로 증가하고 있으며, 특히 2025년 1분기 기준 피해액은 수천억 원 규모에 이르는 등 그 양상이 더욱 심각해지고 있다. 한 번의 피해로도 개인과 가정의 평생 저축이나 노후 자금이 순식간에 사라질 수 있고, 피해자는 경제적 손실뿐 아니라 강한 죄책감과 수치심, 불안감 등 심리적 후유증을 장기간 겪게 된다. 이와 같은 측면에서 보이스피싱 방지는 단순한 금융 보안 차원이 아니

라, 개인의 삶의 질과 인간다운 생활을 지키기 위한 필수 과제라고 볼 수 있다.

또한 보이스피싱 피해는 IT·금융 이해도가 낮은 고령층과 디지털 취약계층에게 집중되는 경향을 보인다. 이는 곧 디지털 정보 격차가 보안·범죄 피해 격차로 직결된다는 것을 의미하며, 방치할 경우 사회적 약자에 대한 2차·3차 피해로 이어질 수 있다. 따라서 이 문제는 일부 개인이나 특정 집단의 문제가 아니라, 사회 전체가 함께 해결해야 할 공공의 문제이다. 반복되는 보이스피싱 사건은 금융기관과 통신사, 공공기관에 대한 신뢰를 떨어뜨리고, 공적 안내 전화나 문자조차 불신의 시선을 받게 만들어 행정 서비스와 사회적 의사소통의 효율성에도 부정적인 영향을 끼친다.

기술적 관점에서도 이 문제는 매우 중요하다. 기존의 방식은 최신 보이스피싱 수법을 충분히 반영하지 못하고 있다. 통화 내용과 맥락을 이해하지 못하는 한, 이러한 시스템은 고도화된 보이스피싱에 대해 근본적인 대응이 어렵다. 더불어 모든 통화 내용을 서버로 전송해 분석하는 방식은 개인정보 보호와 프라이버시 측면에서 한계를 갖고 있기 때문에, 단말기 내부에서 통화 내용을 STT로 변환하고 이를 실시간으로 분석하는 온디바이스 AI 방식이 필요하다. 이와 같이 보이스피싱 방지는 범죄 억제와 피해 예방, 디지털 격차 완화, 개인정보 보호, 신뢰할 수 있는 AI 기술 구현 등 여러 측면에서 동시에 중요성을 갖는 과제이다.

만약 이러한 문제가 해결되지 못할 경우, 보이스피싱 피해 규모는 앞으로도 증가할 가능성이 높으며, 특히 고령층과 취약계층의 빈곤과 불안정이 심화될 수 있다. 금융·통신 시스템 전반에 대한 신뢰가 붕괴할 경우, 디지털 전환과 비대면 서비스 확대에도 부정적 영향을 미칠 수 있다. 더 나아가 딥보이스, 딥페이크 기술과 결합된 새로운 유형의 보이스피싱이 등장할 경우, 국내를 넘어 글로벌 차원의 보안 이슈로 확

산될 수 있다. 이러한 이유로 본 과제에서 다루는 보이스피싱 탐지 및 경고 시스템 개발은 시의성과 공익성을 동시에 갖춘 중요한 문제라 할 수 있다.

4. 자료조사 및 결과분석

본 장에서는 보이스피싱 탐지를 위해 수행된 기존 연구들을 기술적 관점과 정책·심리적 관점에서 분석하고, 본 프로젝트의 핵심 기술인 'Knowledge Distillation'의 세부 기법들을 비교 분석한다.[1-5, 7-10]

4.1. 기존 연구 분석

기존 연구는 크게 탐지 모델 개발을 중심으로 한 기술 연구와, 범죄 특성 및 정책을 분석한 연구로 구분된다.

4.1.1 통화 내용 분석을 통한 보이스피싱 범죄 탐지 (석사학위논문)

- **핵심 내용:** 보이스피싱 탐지를 위한 한국어 정형 데이터셋 'KorCCVi'를 최초로 구축하고, Shallow ML과 딥러닝 모델의 성능을 비교하였다.
- **결과:** LGBM 모델이 정확도 99%, F1-score 99%로 딥러닝 모델(RNN, BiLSTM 등)보다 우수한 성능과 속도를 보임을 입증하였다.

4.1.2 딥러닝 기반 NLP 및 지식증류기법을 활용한 보이스피싱 의심 발언 탐지 (학술지)

- **핵심 내용:** On-device 환경에서의 실시간 탐지를 위해 Teacher 모델의 지식을 Student 모델로 전이하는 Knowledge Distillation 기법을 제안하였다.
(KoELECTRA-base → KoELECTRA-small)
- **결과:** 경량화된 Student 모델이 Teacher 모델(정확도 0.98)에 근접한 정확도 0.96을 달성하여 효율성을 입증하였다.

4.1.3 Enhanced Voice Phishing Detection Using an LLM-Based

Framework (IEEE Access)

- **핵심 내용:** 데이터 부족 문제를 해결하기 위해 LLM(GPT-4)으로 고난도 시나리오 데이터를 증강하고, 도메인 전문가의 분석 기준을 프롬프트에 적용하였다.
- **결과:** 기존 모델이 취약했던 모호한 케이스에서 F1-score 0.9686을 기록하며 성능을 대폭 향상시켰다.

4.1.4 KoBERT 기반의 통화내용 분석을 통한 보이스피싱 예방 서비스 개발 (학술지)

- **핵심 내용:** 금융감독원 데이터와 KoBERT 모델을 활용하여 통화 위험도를 3단계(안전/주의/위험)로 시각화하고 예방 콘텐츠를 제공하는 통합 서비스를 개발하였다.
- **결과:** 10 Epoch 학습 시 97.87%의 정확도를 달성하였다.

4.1.5 신종 AI 보이스피싱 탐지를 위한 모델링 및 실시간 알림 시스템 (학술대회)

- **핵심 내용:** 생성형 AI가 만든 Deep Voice의 음향학적 특징을 스펙트로그램으로 분석하여 탐지하는 기법을 제안하였다.
- **결과:** AI 음성은 8kHz 이상 고주파수 에너지가 부족하고 억양 변화가 단조롭다는 특징을 규명하였다.

4.1.6 심리적 기재를 기반으로 한 신종 보이스피싱의 특성 연구 (학술지)

- **핵심 내용:** 최근 보이스피싱이 피해자를 외부와 격리(감금)하여 판단력을 흐리게 한 뒤 금품을 갈취하는 형태로 진화했음을 범죄 스크립트 분석을 통해 규명하였다.

4.1.7 음성데이터 활용 보이스피싱 대응 연구 (학술지)

- **핵심 내용:** 개인정보보호법 등 법적 규제에 의한 기술 개발의 어려움을 분석하고, 데이터 가명/익명화 처리 허용 및 동의 절차 개선 등의 정책적 대안을 제시하였다.

위 연구들을 종합해 볼 때, 최근 보이스피싱 탐지 기술은 다음과 같은 경향을 보인다. 모델은 한국어의 문맥적 특성을 반영하기 위해 KoBERT, KoELECTRA 등 사전 학습된 언어 모델을 주로 채택하고 있으며, 모바일 환경에서의 실시간성을 확보하기 위해 Knowledge Distillation 기법이나 경량 모델 도입이 필수적으로 요구되고 있다. 데이터는 데이터 신뢰성 확보를 위해 공공 데이터(금융감독원, AIHub)를 기반으로 하되, 최근에는 LLM을 활용한 데이터 증강을 통해 데이터 희소성 및 클래스 불균형 문제를 해결하는 방식이 적극 도입되고 있다.

4.2. 핵심 기술 심층 분석: Knowledge Distillation

본 프로젝트의 핵심 목표인 '온디바이스 경량 탐지 모델' 구현을 위해서는 고성능 모델의 정보를 손실 없이 경량 모델로 전달하는 것이 필수적이다. 이를 위해 다양한 Knowledge Distillation 기법을 방법론에 따라 세분화하여 분석하였으며, 그 결과는 [표 1]과 같다.

연도/기법명	핵심 아이디어	해결한 문제	유의 사항
2014/15 Feature-based KD	중간 레이어의 특징맵(Feature map) 자체를 모사	결과값만 맞추는 얕은 학습 방지, 사고 과정 학습	교사-학생 레이어 차원 불일치 시 투영 필요
2015 Vanilla KD (response-based KD)	최종 출력(Logit)에 Temperature 적용해 분포 학습	정답(Hard label) 외 클래스 간 미세한 관계 정보 전달	하이퍼파라미터(T, alpha)에 따른 성능 민감도 높음
2019 RKD (Relational KD)	배치 내 데이터 간의 거리/각도 관계(Relation) 학습	개별 값 학습 시 놓치는 구조적 상호관계 정보 보완	배치 크기(Batch size)가 작으면 관계 형성 어려움
2019 TA-KD (Teacher Assistant KD)	중간 크기 '조교' 모델을 통해 단계적 지식 전달	교사-학생 격차(Capacity Gap)로 인한 성능 저하 방지	조교 모델 추가 학습으로 인한 시간/비용 증가
2020~ Curriculum	쉬운 데이터에서 어려운 데이터 순, 혹은 고품질 선별	무작위/저품질 데이터로 인한 학습 효율 저하 방지	난이도/품질 점수 기준(Scoring)의 정 확성 중요
2021~ Hidden states- based Distillation	(LLM용) 내부 은닉 벡터정렬	단순 확률로 전달 힘든 문맥/추론 능력 전이	레이어 매핑 전략 수립 중요, 높은 메모리 소모
2023~ 랭킹 최적화	선호하는 답변에 더 높은 순위(Rank) 부여	문법은 맞으나 부자연스럽거나 선호도 낮은 답변 개선	고품질 선호도 데이터셋(Pairwise) 구축 필수
2023~ SKL/SRKL 기반 Contrastive KD	대칭/역방향KL 및 대조 학습으로 다양성 확보	답변이 지나치게 평범해 지는 현상 개선	복잡한 손실 함수로 인한 학습 불안정성 주의

[표 1] Knowledge Distillation 주요 기법 비교 및 분석

분석 결과, 단순한 Vanilla KD는 구현이 용이하나 복잡한 문맥 정보를 전달하는 데 한계가 있다. 따라서 본 프로젝트에서는 Feature-based

KD를 채택하여 Teacher 모델의 중간 레이어 정보를 Student 모델에 직접 전달함으로써 성능 손실을 최소화하고, 향후 고도화 단계에서 LLM 특성에 맞는 Hidden states-based 기법의 적용 가능성을 열어 두기로 한다.

5. 아이디어 창출과정

아이디어 창출을 위해서 매주 공통된 주제 범위 내에서 관심이 있는 최신 연구 논문 내용들을 탐색하고, 핵심 내용을 요약하여 공유하는 세미나를 진행하였다. 각 연구에서 사용된 데이터 활용 방식이나 모델 평가 방식 등 추후 프로젝트 연구 설계에 도움이 될 만한 인사이트를 도출하였다.

초기 탐색 주제는 'LLM Jailbreak(탈옥) 방어 및 공격'이었다. 그러나 최신 보안 이슈 특성상 학부 수준에서 접근 가능한 데이터와 검증된 레퍼런스가 부족하였고, 지도 교수님의 전문 분야와 연계하여 보다 실질적인 조언을 얻을 수 있는 주제로의 전환을 결정하였다. 이에 사회적 문제로 대두되고 있는 '보이스피싱 탐지'를 새로운 주제로 선정하였으며, 음성 신호 처리(Signal Processing)와 자연어 처리(NLP) 중 텍스트 기반의 NLP 분류 모델에 집중하기로 결정하였다.

프로젝트의 방향성은 크게 두 가지로 나뉜다. '고성능 달성'과 '경량화를 통한 실용성 확보'이다. 4.1의 자료조사에 따르면, 기존의 대형 모델들은 이미 높은 탐지 성능을 보이고 있으나 실제 사용자 환경에서의 활용성은 떨어지는 경향이 있었다. 따라서 본 프로젝트는 **기존 SOTA 모델의 성능을 유지하면서 온디바이스(On-device) 구동이 가능한 경량화 모델 개발**을 핵심 목표로 설정하고 브레인스토밍을 진행하였다.

도출된 주요 아이디어는 다음과 같다.

- 음성 데이터를 텍스트로 변환(STT) 후 NLP 모델로 추론하는 파이프라인 구축
- 지연 시간(Latency)을 최소화하여 실시간 추론이 가능한 시스템 구현
- 단순 이진 분류를 넘어, 대화 흐름에 따른 '실시간 피싱 위험도' 시각화
- 탐지 후, 대화 맥락에 맞는 구체적인 대처 가이드라인(Action Plan) 제시
- Knowledge Distillation 기법을 적용하여 모델 용량 최적화
- 화자 분리(Speaker Diarization)를 통해 피싱범의 발화 의도를 집중 분석
- 민감한 통화 데이터의 외부 유출을 막기 위한 온디바이스 처리 구조 설계 (Privacy Preserving)

6. 아이디어 분석 및 평가과정

아이디어의 실현 가능성을 검증하기 위해 기존 상용 서비스와 학술 연구를 다각도로 분석하였다.

6.1 상용 서비스 및 데이터 분석

시중의 보이스피싱 탐지 서비스들은 주로 통신사의 방대한 음성 데이터를 활용하거나 클라우드 서버 기반의 분석을 수행한다. 그러나 본 프로젝트에서 민감한 개인정보가 포함된 실제 보이스피싱 음성 데이터를 대량으로 확보하는 것은 불가능에 가깝다. 이에 대한 대안으로 LLM(Large Language Model) 기반의 데이터 증강(Data

Augmentation) 기법을 도입하여, 공개된 소량의 데이터를 기반으로 고품질의 학습 데이터를 생성하고 클래스 불균형 문제를 해결하기로 결정하였다.

6.2 베이스 모델 선정 및 사전 실험

기존 연구(표 참고)를 분석한 결과, 대부분 효율적인 인코더(Encoder) 기반 모델을 채택하고 있음을 확인하였다. 이를 바탕으로 한국어 성능이 입증된 Klue/RoBERTa와 최신 모델인 A.X. encoder를 후보군으로 선정하여 비교 실험을 진행하였다. 사전 실험 결과, 두 모델 모두 소량의 데이터로도 높은 이진 분류 정확도를 보였으며 학습 속도 또한 우수하였다. 이에 개발 용이성과 레퍼런스가 풍부한 RoBERTa를 초기 베이스 모델로 선정하고, 추후 A.X. encoder로의 확장을 고려하는 단계적 개발 계획을 수립하였다.

6.3 경량화 및 STT 모델 선정

핵심 목표인 '온디바이스 구동'을 위해 Knowledge Distillation 기법을 적용하였다. 단순한 출력값 모방을 넘어, Teacher 모델의 내부 표현력까지 학습할 수 있는 Feature-based KD 방식을 채택하여 성능 손실을 최소화할 계획이다. 또한, 음성을 텍스트로 변환하는 STT 단계에서는 whisper-base/large, faster-whisper-large-v3-turbo 등을 비교 실험하였다. 외부 API 모델은 지속적인 운영 비용 발생과 통화 내용 서버 전송에 따른 보안 이슈가 존재하므로 배제하였으며, 로컬 환경에서 구동 가능하면서도 속도와 정확도 밸런스가 우수한 v3-turbo를 최종 선정하였다.

추가적인 기술적 난제로는 화자 분리의 정확도 확보와 적절한 대처 방안 데이터베이스 구축이 식별되었으며, 이는 후속 연구 과정에서 해결 방안을 모색하기로 하였다.

7. 선정된 최종 아이디어

아이디어 분석과 평가 과정을 통해 현재 최종적으로 결정된 아이디어는 다음과 같다.

1. 금감원에서 제공하는 보이스 피싱 관련 데이터를 사용하되, 데이터 유형의 불균형과 더 많은 데이터를 활용하기 위해서 LLM 증강기법과 전통적인 텍스트 데이터 증강기법을 활용한다.
2. faster-whisper-large-v3-turbo와 BERT기반 모델을 사용하여 실시간 동작이 가능한 end-to-end 모델을 개발한다.
3. Knowledge Distillation 기법을 통해 온디바이스 수준의 모델 경량화를 진행한다.
4. 실시간으로 대화 진행에 따라 피싱 위험도를 평가한다.
5. 대화 종료 후 사용자가 보이스 피싱에 대처할 수 있도록 대화 내용에 맞는 적절한 대처 방안을 제시한다.

7.1 각 아이디어에 대한 기대효과

7.1.1. 균형 있는 데이터 확보 및 가이드라인 제시

기존 연구의 한계인 데이터 부족 및 불균형 문제를 해결하고, 피싱 유형(기관 사칭, 대출 사기 등)별 맞춤형 대응이 가능한 모델 학습의 기반을 마련한다. 이는 향후 관련 연구에 있어 데이터 확보 가이드라인이 될 수 있다.

7.1.2 타 분야로의 확장성

API에 의존하지 않는 로컬 기반 실시간 처리 기술은 보이스피싱 탐지뿐만 아니라 실시간 통역, 회의 요약 등 다양한 온디바이스 AI 애플리케이션 개발에 응용될 수 있다.

7.1.3 모델 경량화 기준점 제시

모바일 환경에서 성능을 유지하며 어느 수준까지 경량화가 가능한지에 대한 기술적 기준점을 제시한다.

7.1.4 범죄 예방 및 사용자 역량 강화

실시간 경고를 통해 즉각적인 범죄 예방이 가능하며, AI가 제공하는 대처 가이드라인을 통해 사용자가 스스로 범죄에 대응할 수 있는 능력을 배양하도록 돕는다.

8. 아이디어 다듬기

선정된 아이디어의 잠재적 기술 난제와 한계를 분석하고, 이를 보완하기 위한 구체적인 기술적 대응 방안을 수립하였다. 또한, 초기 구상 단계에서 보류되었던 아이디어의 장점을 재검토하여 향후 고도화 과정에 반영하였다.

8.1 선택된 아이디어의 단점 보완 방안

핵심 기능 구현 과정에서 발생할 수 있는 데이터 신뢰성, 시스템 지연, 모델 성능 저하, 오탐 등의 문제를 해결하기 위해 다음과 같은 보완책을 적용한다.

8.1.1 LLM/전통적 기법 활용 데이터 증강 아이디어 보완

생성형 AI를 통해 증강된 데이터가 실제 보이스피싱 통화의 언어적 특성을 제대로 반영하지 못하거나, 모델 학습에 부정적 영향을 미치는 환각(Hallucination) 현상이 발생할 우려가 있다. 따라서, 데이터의 신뢰성 및 실제 모델 성능 향상 기여도를 검증할 필요가 있다. 이를 위해 다각적인 데이터 검증 과정을 도입한다.

- (1) 생성 데이터 포함 여부에 따른 모델 성능 개선 정도를 비교
- (2) 원본 데이터와 생성 데이터 간 통계적 유사성을 분석(KL/JS Divergence, t-SNE 시각화)
- (3) 사람을 통한 품질 평가 및 검증 설문조사 진행 → 생성된 데이터의 신뢰성 확보

8.1.2 faster-whisper + BERT 경량화 모델 개발 아이디어 보완

STT 모델인 faster-whisper-large-v3-turbo의 크기와 로컬 환경에서의 실시간 STT 성능 확보가 불확실하다는 단점이 있다. 이에 따라 STT Latency 최적화를 위해 STT 엔진의 실시간 스트리밍 모드 활용 및 최적화 연구를 진행한다. 초기 실험 후 실시간성 기준을 충족하지 못할 경우, 더 가벼운 STT 모델(예: Whisper Medium/Base 또는 경량 한국어 STT)로의 대체나 앙상블 적용을 검토하는 대안 모델 검토 계획을 수립하였다.

8.1.3 Knowledge Distillation를 통한 경량화 아이디어 보완

Knowledge Distillation 과정에서 Teacher 모델의 지식이 Student 모델로 충분히 전이되지 못해 성능이 크게 하락할 가능성이 존재한다. 이러한 성능 저하를 최소화하기 위해 단순히 최종 로짓(Response-based KD)뿐만 아니라, Teacher 모델의 중간 레이어 표현 정보까지 Student 모델에 전달하는 Feature-based KD 기법을 병행하여 지식 전이의 깊이를 높이는 전략을 채택한다. 어떤 모델을 베이스로 하느냐에 따라 설계 방식이 달라지기 때문에 일단은 쉽게 설계할 수 있는 roBERTa 모델로 프로토타입을 제작 후 테스트 결과에 따라 더 최신 모델로 확장한다.

8.1.4 실시간 대화 진행에 따른 위험도 평가 아이디어 보완

짧은 발화나 문맥이 불완전한 상태에서 오탐이 발생할 위험이 있다. 이를 보완하기 위해 위험도 누적 및 문맥 가중치를 적용한다. 단일 발화만으로 즉시 경고를 내리기보다, 일정 시간(예: 5~10초) 동안의 발화들을 묶어 문맥을 파악하고, 위험 키워드 및 패턴의 누적 빈도를 기반으로 위험도를 점진적으로 상승시키는 로직을 도입한다.

8.1.5 대화 내용 기반 대처 방안 제시 아이디어 보완

단순 매칭 방식으로는 복잡하거나 새로운 피싱 유형에 대한 적절한 대처 방안 제시가 어렵다는 한계가 있다. 이를 극복하기 위해 Multi-Task Learning (MTL) 기반 대응 방안을 구상했다. Teacher 모델 학습 시, 위험도 분류와 함께 '피싱 유형 식별' 태스크를 추가하여, 식별된 유형(기관 사칭, 대출 사기 등)에 따라 사전에 정의된 정교한 대처 방안을 제공하는 모듈을 구현할 계획이다.

8.2. 보류된 아이디어의 활용 및 고도화 계획

초기 아이디어 분석 과정에서 기술적 제약으로 인해 1차 개발 범위에서 제외되었으나, 그 효용성을 인정하여 추후 고도화 단계에서 활용하기로 한 내용은 다음과 같다.

8.2.1 화자 분리(Speaker Diarization) 모듈의 단계적 도입

통화 내용 중 피싱범과 피해자의 목소리를 분리(Speaker Diarization)하여, 피싱범의 발화 의도와 패턴을 집중적으로 분석하고자 하였다. 화자 분리 기술은 피싱범의 발화 의도와 패턴에만 집중하여 분류 정확도를 향상할 수 있다는 장점이 있으나, 높은 연산량을 요구하여 STT 과정의 지연 시간을 가중시킬 수 있다. 따라서 실시간성이 최우선인 1차 프로토타입에서는 전사문 전체를 분석 대상으로 하되, 최적화가 완료된 시점에서 심화 연구 과제로 도입한다. 화자 분리 모듈(예: Pyannote/Diarf 등)을 도입하여 피싱범의 발화에 가중치를 부여하는 방식으로 탐지 정확도를 극대화할 예정이다.

9. 프로젝트 목표 구체화

9.1 생성형 AI를 통한 데이터 증강

- a. 현재 공개된 데이터셋에서, 보이스피싱 데이터는 정상 데이터와

달리 굉장히 적고, 그 수법 또한 고르게 존재하지 않는다.

• KorCCVi 데이터셋 구성표

Source	Class (Label)	Samples	Percentage
FSS ¹	Voice phishing (1)	695	23.7%
NIKL ²	Non-voice phishing (0)	2232	76.3%
Total		2927	100%

¹ The Financial Supervisory Service of Korea (FSS); ² The National Institute of the Korean Language (NIKL) website.

<그림 1> KorCCVi 데이터셋 구성표 [11]

유형 구분	파일 개수	문장 개수
바로 이 목소리	94	3,853
대출 사기형	185	8,636
수사기관 사칭형	227	20,991
전체 합계	506	33,480

[표 2] 금융감독원 보이스피싱 데이터 구성 및 통계

공개되어있는 KorCCVi 데이터셋의 경우, <그림 1>을 보면 보이스피싱 데이터가 일반 데이터와 비교해 3배 넘게 더 적은 것을 확인할 수 있다. 또 이 데이터셋에서 이용한 보이스피싱 데이터의 출처인 금융감독원 웹페이지를 찾아 직접 데이터를 스크래핑해 분석해본 결과[6][표 2], 보이스피싱의 유형 또한 대출 사기형과 수사기관 사칭형이 대부분이었고 납치 빙자 유형의 경우 7개만을 확인할 수 있었다. 따라서 이 문제점을 해결하기 위해 현재 서비스되고 있는 생성형 AI(ex. ChatGPT, Gemini 등)에 프롬프트를 입력해 보이스피싱 데이터를 생성하고자 한다. 이를 통해 공개된 보이스피싱 데이터양보다 많이 증강하여 모델 학습에 이용한다.

b. 생성형 AI로 만든 데이터가 실제 모델 성능 향상에 도움이 되려

면, 그 데이터가 신뢰할 수 있는지 먼저 검증해야 한다.

이를 위해 첫째, 생성 데이터 포함 여부에 따라 모델 성능이 실제로 개선되는지 대조군과 비교해 실용성을 확인한다.

둘째, 원본 데이터와 생성 데이터가 통계적으로 얼마나 유사한지 (KL Divergence, JS Divergence, t-SNE 시각화 등) 분석해 평가한다. 셋째, 설문조사를 통해 사람이 직접 실제 데이터와 생성 데이터를 구분해보고 평가해보는 방식을 통해 품질을 검증한다.

이러한 다각적 검증을 통해, 생성된 데이터가 원본의 특성을 제대로 반영하고 모델 학습에 신뢰성 있게 활용될 수 있는지 확인할 예정이다.

9.2 경량화된 보이스피싱 탐지 시스템 구현

a. 사용자의 핸드폰에 실제로 적용이 가능할 만한 인코더 모델을 구현한다.

b. 사용자의 음성을 받아 자동으로 인코더 모델을 이용해 보이스피싱을 탐지하고 이에 따른 출력을 내보내는, 일련의 과정을 수행하는 간단한 애플리케이션을 구현한다.

9.3 실시간적 동작 구현

실시간 동작이 가능한 STT 알고리즘을 작성하고, STT 작업에서 발생할 수 있는 hallucination을 줄여 좋은 품질을 가지는 전사문을 확보한다.

사용자가 통화한 대화를 계속적으로 모델에 입력해 보이스피싱을 탐지하게 한다. 이는 보이스피싱으로 인한 피해가 나오지 않도록 최대한 빠르게 사용자에게 알리는 것이 중요해, 빠른 시간 내에 보이스피싱을 탐지하고 사용자에게 전달할 수 있도록 한다.

10. 아이디어 테스트

본 프로젝트의 핵심 기능 구현에 앞서, 유사한 기능을 수행하는 오픈

소스 프로젝트(Voice-Phishing-Detection-App)를 기반으로 초기 프로토타입 테스트를 진행하였다. 이 과정을 통해 개발 환경의 적합성을 검증하고, 발생 가능한 기술적 문제점을 사전에 식별하여 해결책을 마련하였다.

10.1. 테스트 대상 및 환경

- **테스트 대상:** KoBERT 기반 보이스 피싱 탐지 모델 오픈 소스
- **목적:** 음성 탐지 모델 구동을 위한 최적의 OS 및 라이브러리 환경 도출

10.2. 문제점 발견 (Windows 환경)

- **현상:** Windows 운영체제에서 해당 서버 코드 구동 시, 다수의 라이브러리 간 의존성 충돌 현상이 발생하였다.
- **원인 분석:** Windows 환경 특성상 특정 AI 라이브러리의 호환성 문제가 지속적으로 발생하였으며, 해결을 위해서는 라이브러리 내부 소스 코드를 직접 수정해야 하는 등 유지보수 측면에서 비효율성이 크다고 판단되었다.


10.3. 개선 과정 및 결과 (Linux 환경 전환 및 최적화)

- **해결 방안 1 (OS 전환):** 라이브러리 호환성과 개발의 안정성을 확보하기 위해, 주 개발 환경을 Windows에서 Linux로 전면 전환하기로 결정하였다.
- **해결 방안 2 (버전 최적화):** Linux 환경에서의 재검증 과정에서, 최신 버전의 numpy가 mxnet이 필요로 하는 속성을 지원하지 않아 발생하는 오류(Attribute Error)가 식별되었다. 이에 대한 해결책으로 numpy 라이브러리를 1.23.1 버전으로 다운그레이드(Downgrade)하여 호환성 문제를 해결하였다.

위 과정을 통해 서버가 정상적으로 구동됨을 확인하였으며, 프로젝트 개발을 위한 안정적인 베이스라인 환경을 구축하였다.

11. 설계내용

본 프로젝트의 최종 설계안은 <그림 3>과 같이 크게 '데이터 구축, ' 모델 학습 및 경량화, '온디바이스 서비스'의 3단계 프로세스로 구성된다.



<그림 2> 전체 시스템 구조도 및 데이터 흐름도

11.1 데이터 전처리 및 증강

시스템의 초기 입력은 보이스피싱 및 정상 통화 음성 데이터이다. 음성 데이터는 STT 엔진을 거쳐 텍스트로 변환되며, 보이스피싱 여부가 레이블링 된 원본 데이터셋으로 1차 저장된다. 이 과정에서 인식 오류 최소화를 위해 불필요한 문자 제거, 중복 발화 처리, 문장 분할 등의 전처리를 수행한다. 이후 데이터 부족 문제를 해결하기 위해 생성형 AI 기반의 데이터 증강을 수행한다. 수집된 원본 데이터를 바탕으로 다양한 피싱 시나리오를 생성하여 증강 데이터셋을 구축해, 이를 원본

과 동일한 전처리 과정을 거쳐 병합함으로써 최종 학습용 데이터셋을 완성한다.

11.2 Teacher 모델 학습 및 Knowledge Distillation

전처리가 완료된 데이터셋을 사용하여 먼저 고성능 Teacher 모델을 학습시킨다. Teacher 모델은 피싱 위험도 판별과 핵심 정보 분석을 동시에 수행하는 MTL 구조로 설계되었으며, 실제 배포 환경의 제약보다는 '최대 성능과 문맥 이해 능력 확보'를 최우선 목표로 한다.

이후 학습이 완료된 Teacher 모델을 기반으로 Knowledge Distillation 과정을 수행한다. 이는 방대한 파라미터와 연산량을 가진 Teacher 모델이 학습한 데이터의 특징과 복잡한 판단 논리를, 구조가 단순한 Student 모델이 효율적으로 모방하여 학습하도록 하는 기법이다.

이 과정을 통해 Student 모델은 Teacher 모델이 가진 고차원의 지식을 전수받아, 적은 용량과 빠른 연산 속도를 유지하면서도 Teacher 모델에 준하는 높은 탐지 성능을 발휘할 수 있게 된다. 이는 고성능 연산이 어려운 온디바이스 환경에서 실시간성과 정확도를 동시에 확보하는 End-to-End 시스템 구현의 핵심 전략이다.

11.3 온디바이스 실시간 탐지 및 대응

최종 단계에서는 학습된 Student 모델을 탑재하여 실제 서비스를 구현한다. 시스템은 STT를 통해 실시간으로 유입되는 텍스트 스트림을 분석하여 피싱 위험 수준을 단계별로 판별한다. 동시에 위험 상황에 맞는 맞춤형 예방 안내 및 대응 팁을 생성하여 사용자에게 제공한다. 본 설계의 핵심은 이 모든 분석 및 추론 과정이 end-to-end로 설계된다는 점이며, 이를 통해 네트워크 지연 없는 실시간성과 민감 데이터의 보안성을 동시에 확보한다.

12. 설계평가

본 설계안은 고성능 AI 모델의 성능을 유지하면서도 모바일 환경에서 구동 가능한 경량화 및 실시간성을 확보했다는 점에서 다음과 같은 기술적 특징과 독창성을 갖는다.

12.1.1 Knowledge Distillation 기반의 고성능 경량화

가장 큰 기술적 특징은 MTL 기반의 거대 Teacher 모델이 학습한 문맥 이해 능력과 위험 판별 지식을 Soft Target 형태로 추출하여, 경량화된 Student 모델에 전이시킨다는 점이다. 이를 통해 구조적으로 단순한 모델임에도 불구하고 Teacher 모델에 준하는 높은 성능을 발휘하도록 설계하였으며, 이는 고성능과 저사양 배포 환경(On-device)이라는 상충되는 요구사항을 동시에 만족시키는 핵심 기술 기반이 된다.

12.1.2 스트림 처리 구조를 통한 실시간 개입

기존의 사후 분석(Post-call Analysis) 방식과 달리, STT가 생성하는 부분 텍스트(Partial Result)를 0.5~1초 단위의 스트림으로 수신하여 즉시 분석하는 구조를 채택하였다. 문장이 완성되기 전이라도 의심 패턴이 감지되면 위험 단계를 즉각 상향 조정하여 경고를 제공함으로써, 피해 발생 전인 ‘대화 중’에 능동적으로 개입할 수 있다는 차별화된 장점을 가진다.

12.2. PMI 기법을 활용한 설계 목표 달성 평가

본 절에서는 설계 초기 목표(G1~G5)를 기준으로 PMI(Plus-Minus-Interesting) 기법을 적용하여, 각 목표의 달성 수준과 한계점 및 향후 개선 방향을 체계적으로 평가하였다. 상세 평가 내용은 다음 [표 3]와 같다. 이를 통해 관련 연구 분석을 통해 모델 개발의 구현 가능성이 높다는 점을 시사할 수 있다.

[표 3] PMI 기법을 활용한 설계 목표 달성 평가

설계목표	목표내용	Plans (강점)	Minus (리스크)	Interesting (흥미로운점)	정량적 달성 목표 (검증)
G1	온디바이스 구동 가능 경량화	Knowledge Distillation로 성능 대비 크기 최적화	신중 패턴 일반화 성능 저하	DistillIM 계열 양자화 프루닝/추가 경량화 및 성능 보존 가능	• 목표: 모델 크기 50MB 이하 • 현황: 프로토타입 설계 중
G2	실시간 스트림 기반 위험 감지 / 경고	STT를 0.5~1초 단위로 수신 및 분석하여 통화 중 위험 업데이트 및 조기 경고 가능	문맥 미완성으로 오탐/경고 과민 가능, 사용자 신뢰 저하 위험	누적 스코어링 로직 적용	• 목표: 처리 지연(Latency) 1초 이내 • 현황: 스트리밍 구조 확보
G3	성능 유지	Teacher 모델의 지식 모사	생성/다중 테스트 난이도↑, 품질 편차 가능	하이브리드 처리 방식 도입	• 목표: F1-Score 0.90 이상 • 현황: 베이스라인 비교 예정
G4	프라이버시 보호	데이터 외부 전송 '0'	모델 업데이트 제약	온디바이스 아키텍처	• 목표: 외부 전송 패킷 0 Byte • 현황: 온디바이스 아키텍처 확정
G5	확장성/유지보수	모듈 간 결합도 최소화	버퍼링/동기화 이슈	폴백(Fallback) 시스템	• 목표: CPU/RAM 점유율 20% 미만 • 현황: 모듈화 설계 완료

13. 참고문헌

[국내 문헌]

1. 김상민, 노승민. (2024). 딥러닝 기반 NLP 및 지식증류기법을 활용한 보이스피싱 의심 발언 탐지. 한국전자거래학회지, 29(4), 139-148.
2. 양지훈, 이충훈, 김성백. (2023). KoBERT 기반의 통화내용 분석을 통한 보이스피싱 예방 서비스 개발 및 활용. 정보과학회 컴퓨팅의 실제 논문지, 29(5), 205-213.
3. 오세연, 송혜진. (2023). 심리적 기재를 기반으로 한 신종 보이스피싱의 특성 및 진행과정에 관한 연구. 한국재난정보학회논문집, 19(3), 510-518.
4. 유지현, 한효정, 이우진. (2025). 신종 AI 보이스피싱 탐지를 위한 모델링 및 실시간 알림 시스템. 한국컴퓨터정보학회 동계학술대회 논문집, 33(1), 351-353.
5. 이비현, 김희두, 김대호. (2025). 음성데이터 활용 보이스피싱 대응 연구: AI 탐지기 술과 법·제도적 요건 적용을 중심으로. 치안정책연구, 39(1), 285-315.
6. 금융감독원 보이스피싱 체험관: 바로 그 목소리, 그놈 목소리 데이터셋, <https://www.fss.or.kr/fss/bbs/B0000203/list.do?menuNo=200686>

[국외 문헌]

7. Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the knowledge in a neural network. arXiv preprint arXiv:1503.02531.
8. Li, Y., Liu, Y., Li, P., Jia, Y., & Wang, Y. (2025). Continuous Multi-Task Pre-training for Malicious URL Detection and Webpage Classification. arXiv preprint arXiv:2402.11495.
9. Moussavou Boussougou, M. K. (2020). An Artificial Intelligent Approach To Detect Voice Phishing Crime By Analyzing The Call Content: A Case Study on Voice Phishing Crime in South Korea (Master's thesis). Soongsil University, Seoul.
10. Park, H., Lee, J., Han, S., & Byun, H. (2025). Enhanced Voice Phishing Detection Using an LLM-Based Framework for Data Augmentation and Classification. IEEE Access. doi:10.1109/ACCESS.2025.3603007.
11. Moussavou Boussougou, M. K., Park, D. J. (2023). Attention-Based 1D CNN-BiLSTM Hybrid Model Enhanced with FastText Word Embedding for Korean Voice Phishing Detection. Mathematics, 11(14), 3217.