

2026-1학기 캡스톤 디자인2 중간 보고서	
프로젝트명	텍스트 기반 보이스피싱 탐지 시스템 개발
팀원	(22102304) 김나현 (21102389) 정지훈

1. 프로젝트의 개요

본 프로젝트는 점차 지능화되고 교묘해지는 보이스피싱 범죄로부터 사용자의 금전적, 정신적 피해를 예방하기 위한 **인공지능 기반의 실시간 보이스피싱 탐지 시스템**을 개발하는 것을 목표로 한다.

최근 정보통신기술의 비약적인 발달과 함께 보이스피싱 범죄 수법 역시 정교한 사회공학적인 기법과 딥페이크 음성 합성 등 첨단 기술을 결합하는 형태로 진화하고 있으며, 이로 인한 사회적 피해 규모는 매년 심각한 수준으로 증가하고 있다. 특히 범죄 조직이 금융 기관이나 수사 기관을 사칭하며 피해자의 심리를 교묘하게 압박하는 상황에서는 사용자가 스스로 위험을 인지하기 매우 어렵다. 따라서 통화 내용을 실시간으로 분석하여 대화의 문맥적 위험성을 파악하고, 사용자에게 즉각적으로 경고를 제공할 수 있는 인공지능 기반 방어 시스템의 도입이 매우 시급한 실정이다.

이러한 배경을 바탕으로 본 프로젝트는 음성 인식(STT) 기술을 통해 실시간 통화 음성을 텍스트로 변환하고, 이를 자연어 처리(NLP) 및 딥러닝 모델과 융합하여 사기 의도를 높은 정확도로 탐지하는 지능형 탐지 솔루션 구축을 최종 목표로 한다. 대화 텍스트에 내포된 발화자의 의도, 주요 키워드의 문맥적 흐름, 대화 패턴 등을 분석하여 보이스피싱 확률을 도출하며, 위험 임계치를 초과할 경우 즉각적인 경고 알림을 발생시켜 사용자의 상황 인지를 돕는다. 궁극적으로 본 시스템은 보이스피싱 범죄가 발생하기 직전의 골든타임 내에 피해를 원천적으로 차단하여, 사용자가 안전하게 통신 환경을 이용할 수 있도록 돕는 기술적 보호막 역할을 수행하고자 한다.

2. 프로젝트의 수행 과정 및 수행 내용

캡스톤 디자인 1 이후 진행한 프로젝트 내 실험 내용들은 다음과 같다.

2.1 보이스피싱 탐지와 피해 대처 방안 출력의 통합 효율성 검토

실시간 보이스피싱 탐지 모델이 입력받는 데이터 형태와 대처 방안을 출력하는 모델의 입력 형태가 상이하여, 이를 어떻게 효율적으로 파이프라인화 할 것인지 검토가 필요했다. 음성 데이터를 입력받아 STT로 변환된 대화 텍스트를 모델에 전달하는 방식과 함께, 대처 방안을 LLM 기반의 '완전 생성형 방식'으로 할 것인지, 아니면 대화의 분류에 따른 '정해진 내용 출력 방식'으로 할 것인지 두 가지를 염두에 두고 장단점을 분석하였다.

2.2 온디바이스 적용을 위한 지식 종류 기법 및 PTQ 적용 검토

개발 중인 모델에 어떤 지식 종류 방법을 적용할 수 있고, 적용 가능한 방법을 적용할 수 있는지 실험했다. 우선적으로 DistilBERT와 MiniLM 방식을 적용하여 경량화 시 성능 방어에 문제가 없는지 확인하였다. 또한, 지식 종류의 재학습 시간이 오래 걸린다는 점을 고려

하여 PTQ(Post-Training Quantization, 학습 후 양자화) 기법을 BERT 모델에 추가 적용하여 압축률을 극대화할 수 있을지에 대한 분석과 실험을 병행하고 있다.

2.3 긴 문맥 처리를 위한 최적화 BERT 모델 재탐색

사실상 무한한 대화 컨텍스트를 읽고 보이스피싱을 판단해야 하는 상황에서, 무조건 큰 모델이 적합한지 아니면 작은 모델을 효율적으로 활용할 수 있는지 실험을 진행했다. 전체 텍스트를 한 번에 입력하지 않고 '일정 청크 단위'로 잘라서 입력하는 계획에 맞추어, RoBERTa나 KoELECTRA 모델이 인코딩 파트로 충분하다고 판단하여 새로운 아키텍처 융합 실험을 진행하였다.

2.4. 실시간 탐지를 위한 새로운 아키텍처(Mamba) 적용 및 일반 성능 실험

대화 내용 정보를 순차적으로 누적하고 파악할 수 있는 End-to-End 모델 구성이 필요하다. 그러나 기존 BERT 계열 모델들은 문장 전체의 데이터를 독립적으로 입력받아 처리하는 형태이다. 이를 극복하기 위해 메모리 효율이 뛰어나고 순차적 처리에 강점을 가진 Mamba의 State 업데이트 구조를 도입하였다. 현재 AI HUB의 20개 클래스를 가진 한국어 주제별 일상 대화 데이터를 사용하여, 해당 아키텍처가 기존 모델 대비 성능을 얼마나 개선할 수 있는지 일반화 성능 실험을 진행하고 있다.

3. 프로젝트의 수행 결과 및 목표 달성 정도

3.1. 피해 대처 방안 출력 구조 개선 및 모델 단일화 확정

보이스 피싱 피해 대처 방안을 출력하는 방식에 대해서 두 가지 방법을 고려하였다.

첫 번째는 LLM 모델을 사용하여 매 상황에 맞는 적절한 대처 방안을 생성하여 사용자에게 제공하는 방법이다. 이 방법의 가장 큰 장점은 항상 상황에 맞는 최적의 답변을 사용자에게 제공할 수 있다는 점이다. 하지만 모델의 학습 및 성능 검증 측면에서 보았을 때, 학습을 하기 위한 정답 스크립트를 작성하기 매우 어렵고 시간이 많이 들뿐만 아니라, 성능 검증의 기준을 설정하기 까다롭다. 또한 온디바이스 모델 개발 목적에 로컬 LLM 모델은 너무 큰 모델이다.

두 번째는 보이스 피싱 탐지 모델의 클래스를 늘려서 보이스 피싱뿐만 아니라 보이스 피싱의 종류도 파악하여 그 종류에 맞는 사전에 설정된 대처 방안을 사용자에게 제공하는 방법이다. 이 방법은 최적의 대처 방안을 사용자에게 제공한다는 것을 보장하기 어렵지만, 보편적인 대처방안을 제공함으로써 어느 정도의 사용자 니즈를 충족시킬 수 있다. 또한 기존에 가지고 있던 학습 데이터의 클래스만 더 세분화해서 분류해서 사용하면 된다는 점에서 더 효율적이다. 그리고 모델을 하나로 줄여서 사용할 수 있다는 점에서도 온디바이스 모델 개발 목적에 부합한다. 따라서 본 프로젝트의 계획을 두 번째 방법으로 변경하였다.

3.2. 온디바이스 적용을 위한 모델 경량화 실험 결과

표 1: 지식 증류 기법별 모델 성능 및 파라미터 감축 비교

방식	모델 구분	Epoch	Params	Val Acc
RoBERTa-DistilBERT	Teacher	10	110M	99.93
RoBERTa-DistilBERT	Student	10	68M	99.89
ModernBERT-MiniLM	Teacher	5	123M	99.94
ModernBERT-MiniLM	TA	3	40.5M	84.42
ModernBERT-MiniLM	Student	10	29.9M	99.94

위 표 1은 두 가지 지식 증류 기법을 적용한 보이스피싱 탐지 모델의 경량화 및 성능 유지 결과를 보여준다. 표의 'Val Acc'는 해당 모델이 피싱과 정상 통화를 올바르게 분류해 낸 순수 정확도 지표이며, 압축을 거친 두 Student 모델 모두 원본(Teacher)과 대등한 99.9% 수준의 높은 정확도를 성공적으로 방어했다. 구조적으로 RoBERTa 기반 모델(DistilBERT)은 레이어 깊이만 절반으로 덜어내어 파라미터를 약 40% (110M→68M) 감축했다. 반면, ModernBERT 기반 모델(MiniLM)은 레이어 깊이와 내부 차원 두께를 모두 절반으로 깎아내는 방식을 통해 파라미터를 약 76% (123M→29.9M) 까지 혁신적으로 덜어냈다. 특히 ModernBERT 방식은 서로 덩치 차이가 큰 Teacher와 Student 사이의 급격한 정보 손실을 막기 위해, 깊이는 유지한 채 두께만 반으로 줄여 지식을 이어받는 TA를 도입하여 극한의 압축률 속에서도 안정적인 학습 방향을 유지한 것이 특징이다.

3.3. 데이터 전처리 고도화 및 실시간 점진적 탐지 아키텍처 적용

수치상 높은 성능 대비 실제 일반화 성능이 떨어져 오버피팅이 의심되었다. 이를 해결하기 위해 아키텍처 설계와 전처리 구조를 전면 개편했다.

■ **데이터 증강 및 계층적 라벨링**: 기존의 단순 KoEDA를 사용한 데이터 증강 방법으로는 유의미한 데이터 일반화 성능을 끌어내지 못하였다. 보이스 피싱 데이터 부족 문제와 클래스 불균형 문제를 해결하기 위해 두 가지 방안을 계획하였다. STT 오차 확률 분포를 분석하여 데이터 증강 시 이 오차를 반영할 수 있도록 변경하고, 각 문장이 탐지에 핵심이 되는지를 3단계로 평가하는 계층적 라벨링 시스템을 새롭게 도입하였다.

■ **동작 메커니즘**: 쪼개진 문장 조각들은 'KoELECTRA(부분 동결/LoRA)'와 '어텐션 풀링'을 거쳐 "계좌이체", "금감원" 등 핵심 위험 단어 중심의 피쳐로 압축된다. 이후 '2-Layer Mamba SSM'으로 전달되어, 메모리 부담 없이 이전 맥락과 결합해 통화가 진행될수록 피싱 확신도(Belief)를 점진적으로 갱신한다. 또한 보이스 피싱 대화 초반에 탐지율을 높이기 위해 대화 초반 오답 패널티를 추가하여 통해 조기 탐지 능력을 향상시키고자 한다.

현재 AI HUB의 주제별 텍스트 일상 대화 데이터를 사용하여 모델의 성능을 테스트 중이며, 결과 피드백과 함께 새로운 데이터 라벨링이 끝나는 대로 실제 보이스 피싱 데이터 학습을 진행할 예정이다.

4. 프로젝트 향후 계획

1) 프로젝트 추진 일정

프로젝트 최종 목표 달성을 위한 남은 과제 및 추진 일정은 다음과 같다.

- 10주차 (아키텍처 확정 및 라벨링 완료): AI HUB 데이터 기반 Mamba 아키텍처 성능 평가 완료 및 실제 보이스피싱 텍스트 데이터의 계층적 라벨링(3단계) 작업 최종 마무리
- 11~12주차 (실제 데이터 본 학습 및 튜닝): 구축된 피싱 데이터를 활용하여 모델 본 학습 진행 & 오버피팅 방지를 위한 하이퍼파라미터튜닝 및 시간 가중치 손실 함수 최적화 수행
- 13주차 (최종 경량화 및 모바일 탑재 준비): 학습이 완료된 최종 단일 모델에 지식 증류(KD) 및 양자화(PTQ)를 적용하여 모바일 구동이 가능한 경량화 포맷으로 변환
- 14~15주차 (애플리케이션 통합 및 테스트): STT 엔진, 프론트엔드 UI(대시보드 및 알림 시스템)와 탐지 모델 연동 & 실시간 지연 시간 및 배터리 소모량 측정, 버그 수정 등 시스템 안정화
- 16주차 (최종 발표 및 데모 준비): 데모 시나리오 점검 및 캡스톤 디자인 최종 결과 보고서 작성

2) 데모 계획

최종 발표회에서는 시스템의 실시간 탐지 성능과 직관적인 사용자 경험을 검증하기 위해, 구현된 AIShield 모바일 애플리케이션 프로토타입 데모를 시연할 예정이다.




그림 1 데모 모바일 어플리케이션

[참고 문헌]

- [1]Clark, K., Luong, M.-T., Le, Q. V., & Manning, C. D. (2020). ELECTRA: Pre-training text encoders as discriminators rather than generators. In Proceedings of the 8th International Conference on Learning Representations (ICLR).
- [2]Gu, A., & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. arXiv preprint arXiv:2312.00752.
- [3]Gu, A., Goel, K., & Ré, C. (2021). Efficiently modeling long sequences with structured state spaces. In Proceedings of the 9th International Conference on Learning Representations (ICLR).
- [4]Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). LoRA: Low-rank adaptation of large language models. In Proceedings of the 10th International Conference on Learning Representations (ICLR).
- [5]Jiao, X., Yin, Y., Shang, L., Jiang, X., Chen, X., Li, L., Wang, F., & Liu, Q. (2020). TinyBERT: Distilling BERT for natural language understanding. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), 4163-4174.
- [6]Park, J. (2020). KoELECTRA: Pretrained ELECTRA model for Korean. GitHub. <https://github.com/monologg/KoELECTRA>
- [7]Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv preprint arXiv:1910.01108.
- [8]Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. In Proceedings of the 34th International Conference on Neural Information Processing Systems (NeurIPS), 5776-5786.
- [9]Yang, Z., Yang, D., Dyer, C., He, X., Smola, A., & Hovy, E. (2016). Hierarchical attention networks for document classification. In Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (pp. 1480-1489).